

SAE S4.C.01 - DÉVELOPPEMENT AVEC UNE BASE DE DONNÉES ET VISUALISATION

Kishan Patel | Alpay Soran | Edvin Thileepan | Abdelraouf Boulfrad

Rendu fourni avec le MLD et le schéma relationnel en pdf, ainsi que les scripts SQL et l'application Qlik (fichier .qvf) .

Dans ce projet, nous avons travaillé sur des données liées à la qualité de l'air provenant de plusieurs sources : OpenAQ, World Cities et World Bank. L'objectif est de structurer, nettoyer et analyser ces données afin de mieux comprendre les facteurs influençant la pollution.

Pour cela, nous avons conçu une base de données relationnelle, puis un modèle multidimensionnel afin de faciliter l'analyse. Des requêtes SQL ont ensuite été réalisées pour exploiter les données et comparer les performances des deux modèles. Enfin, une visualisation des données a été réalisée à l'aide de Qlik afin de mettre en évidence certains résultats et incohérences via une approche stratégique .

1. Analyse des sources de données

Dans ce projet, nous avons utilisé trois datasets principaux : OpenAQ, World Cities et World Bank. Ces datasets ont été choisis car ils permettent d'analyser la pollution selon différents points de vue : environnemental, géographique et économique.

Le dataset OpenAQ contient des données de qualité de l'air provenant de stations réparties dans le monde entier. Chaque enregistrement correspond à une mesure prise à un instant précis.

Nous avons choisi ce dataset car il constitue la source principale de données sur la pollution et permet une analyse temporelle précise.

Champs principaux

Champ	Description
location_id	Identifiant de la station
sensor_id	Identifiant du capteur
datetime	Date et heure de la mesure
latitude / longitude	Coordonnées géographiques
country	Pays
parameter	Type de polluant

value	Valeur mesurée
unit	Unité

Principaux polluants

Polluant	Description	Unité
PM2.5	Particules fines très nocives	µg/m³
PM10	Particules fines	µg/m³
NO ₂	Gaz lié au trafic routier	ppb
CO	Gaz toxique	ppm
O ₃	Polluant secondaire	ppb
SO ₂	Gaz industriel	ppb

Ce dataset permet une analyse temporelle de la pollution, une comparaison entre villes et pays, ainsi que la détection de pics de pollution et de valeurs aberrantes.

Le dataset World Cities contient des données géographiques et démographiques sur les villes. Il permet de relier les données de pollution à des caractéristiques urbaines.

Nous avons choisi ce dataset pour contextualiser les mesures de pollution.

Champs principaux

Champ	Description
city	Nom de la ville
city_ascii	Nom sans accents
lat / lng	Coordonnées
country	Pays
iso2 / iso3	Codes ISO
population	Population
admin_name	Région

Problèmes de qualité : population estimée et non officielle, valeurs nulles possibles, risque de doublons, ainsi que la différence entre les champs city et city_ascii pouvant compliquer les jointures.

Le dataset World Bank contient des indicateurs économiques et environnementaux par pays et par année.

Nous avons choisi ce dataset afin d'analyser les liens entre pollution et contexte économique.

Champs principaux

Champ	Description
country	Nom du pays
country_code	Code ISO
indicator_name	Indicateur
year	Année
value	Valeur

Indicateurs utilisés

Indicateur	Description
PIB	Richesse du pays
CO ₂	Émissions
Urbanisation	% population urbaine
Motor vehicles	Nombre de véhicules

Ces trois datasets sont complémentaires et permettent d'analyser la pollution sous plusieurs angles : environnemental, géographique et économique. Leur combinaison permet d'obtenir une vision globale et plus précise de la qualité de l'air.

2. Modélisation relationnelle des données

Afin de structurer les données issues des différents datasets, nous avons conçu un modèle relationnel. L'objectif est d'organiser les données de manière cohérente tout en évitant les redondances.

Ce modèle permet de relier les différentes sources de données :

- les données de pollution (OpenAQ)
- les données géographiques (World Cities)
- les données économiques (World Bank)

Nous avons choisi une modélisation relationnelle classique afin de garantir l'intégrité des données et de faciliter leur stockage.

Structure du modèle

Le modèle est composé de plusieurs tables reliées entre elles par des clés étrangères. Les relations principales sont les suivantes :

- un pays peut contenir plusieurs villes
- une ville peut contenir plusieurs stations
- une station peut contenir plusieurs capteurs
- chaque capteur est associé à un polluant
- les indicateurs économiques sont associés à un pays et une année

Cette structure suit la logique des datasets utilisés et permet de représenter correctement les relations entre les données.

Choix de modélisation

Plusieurs choix ont été effectués lors de la conception :

- séparation des entités principales (pays, ville, station, capteur, polluant) afin d'éviter les redondances
- utilisation de clés étrangères pour assurer la cohérence des relations
- création d'une table VALEUR_INDICATEUR avec une clé primaire composée (pays, indicateur, année) pour gérer les données temporelles

Nous avons choisi ce modèle car il respecte les principes de normalisation et permet une organisation claire des données. Il est particulièrement adapté au stockage et à la gestion des données.

Limites du modèle

Cependant, ce modèle présente certaines limites dans un contexte d'analyse :

- les requêtes nécessitent plusieurs jointures
- les performances peuvent être limitées pour des analyses complexes

Ces limites ont motivé la mise en place d'un modèle multidimensionnel dans la suite du projet.

3. Extraction et préparation des données

Les données utilisées dans ce projet proviennent de trois datasets complémentaires : OpenAQ, World Cities et World Bank Indicators. L'objectif de cette étape est de transformer les données brutes issues des datasets en données exploitables dans une base relationnelle.

Ces sources permettent d'analyser la qualité de l'air à différentes échelles :

- locale (stations de mesure)
- urbaine (villes)
- nationale (pays)

Dataset OpenAQ

Le dataset OpenAQ contient des mesures de pollution atmosphérique collectées par des stations situées dans différents pays.

Les principaux champs utilisés sont :

- location_id : identifiant de la station
- sensor_id : identifiant du capteur
- parameter : type de polluant
- value : valeur mesurée
- unit : unité
- datetime : date et heure
- latitude / longitude : coordonnées
- country : pays

Ces données alimentent les tables :

STATION
CAPTEUR
POLLUANT

Dataset World Cities

Le dataset World Cities fournit des informations géographiques et démographiques.

Champs principaux :

- city / city_ascii
- lat / lng
- country
- iso2 / iso3
- population
- admin_name
- capital

Ces données alimentent :

PAYS
VILLE

Les coordonnées permettent également de relier les villes aux stations de mesure.

Dataset World Bank

Le dataset World Bank Indicators contient des données économiques par pays et par année.

Champs principaux :

- country
- country_code
- indicator_name
- year
- value

Ces données alimentent :

INDICATEUR
VALEUR_INDICATEUR

Elles permettent d'analyser les liens entre pollution et contexte socio-économique.

Nettoyage des données

Avant l'intégration, plusieurs opérations de nettoyage ont été réalisées afin d'assurer la qualité et la cohérence des données.

Par exemple, certaines valeurs manquantes ont été supprimées à l'aide de requêtes SQL :

```
DELETE FROM station  
WHERE latitude IS NULL;
```

```
DELETE FROM valeur_indicateur  
WHERE valeur IS NULL;
```

Ces opérations illustrent le type de nettoyage réalisé sur les données avant leur intégration.

Nous avons choisi de supprimer ces données afin d'éviter des biais dans les analyses et de garantir la cohérence des résultats.

Gestion des valeurs manquantes

Certaines données étaient incomplètes :

- stations sans coordonnées
- villes sans population
- mesures sans valeur

Ces enregistrements ont été supprimés ou ignorés afin d'éviter les incohérences.

Suppression des doublons

Les doublons présents dans les datasets ont été identifiés et supprimés afin d'éviter la redondance des données.

Uniformisation des unités

Les unités de mesure ont été harmonisées pour garantir la cohérence :

- PM2.5 et PM10 => $\mu\text{g}/\text{m}^3$
- gaz (NO_2 , CO, O_3 , SO_2) => ppm ou ppb

Normalisation des noms

Les noms de villes ont été uniformisés (ex : Paris, PARIS, Paris city) en utilisant le champ **city_ascii**, afin d'éviter les erreurs de jointure.

Insertion des données

Les données ont été insérées dans la base en respectant un ordre précis afin de garantir l'intégrité référentielle :

1. PAYS
2. VILLE
3. STATION
4. POLLUANT
5. CAPTEUR
6. INDICATEUR
7. VALEUR_INDICATEUR

Cet ordre permet d'assurer que toutes les relations entre les tables sont correctement respectées. Cette étape de préparation est essentielle car elle conditionne la qualité des analyses réalisées par la suite.

Cette étape de préparation est essentielle, car des données mal nettoyées peuvent entraîner des analyses incorrectes et fausser les résultats obtenus.

4. Modélisation de la Base de Données Multidimensionnelle

Structure du modèle

Le modèle adopté est une constellation, composée de plusieurs tables de faits partageant des dimensions communes.

Table de faits

La table **FAIT_MESURE** contient les données principales à analyser, notamment :

- la valeur de pollution mesurée
- les identifiants vers les dimensions (temps, localisation, polluant, pays)

Elle représente donc les mesures de pollution observées.

La table **FAIT_INDICATEUR** contient les données économiques, notamment :

- les valeurs des indicateurs (PIB, CO₂, etc.)
- les identifiants vers les dimensions (pays, temps, indicateur)

Elle permet d'analyser le contexte socio-économique des pays.

Tables de dimensions

Plusieurs dimensions permettent d'analyser ces données selon différents axes :

- **DIM_TEMPS** : permet d'analyser l'évolution de la pollution dans le temps (année, mois, jour, saison)
- **DIM_LOCALISATION** : permet d'analyser les données selon la localisation (station, ville, pays, coordonnées, population)
- **DIM_POLLUANT** : permet de distinguer les différents types de polluants (nom, code, unité, catégorie)
- **DIM_PAYS_ECONOMIE** : permet d'intégrer les informations économiques des pays (PIB, CO₂, etc.) en fonction du pays et de l'année

Choix de modélisation

Au départ, une modélisation plus proche du modèle relationnel avait été envisagée, en conservant plusieurs tables techniques comme CAPTEUR ou STATION.

Cependant, cette approche présentait certaines limites :

- un grand nombre de tables
- des requêtes complexes avec de nombreuses jointures
- une structure peu adaptée à l'analyse décisionnelle

Suite à cette réflexion, le modèle a été simplifié pour adopter un modèle multidimensionnel de type constellation.

Ainsi :

- les tables techniques ont été intégrées dans la dimension **LOCALISATION** afin de réduire le nombre de jointures
- les données ont été dénormalisées pour améliorer les performances des requêtes

- les indicateurs économiques ont été regroupés par pays et par année afin de permettre des analyses croisées avec les données de pollution

Améliorations proposées

Afin d'améliorer le modèle, plusieurs évolutions ont été envisagées :

- ajout d'attributs temporels supplémentaires (semaine, trimestre, saison) pour affiner les analyses
- enrichissement de la dimension localisation avec le continent ou le code pays
- amélioration de la dimension polluant avec une catégorie (gaz, particules) et un impact sur la santé
- possibilité de séparer les indicateurs économiques dans une dimension dédiée pour éviter la redondance des données

Ces améliorations montrent une réflexion sur l'optimisation du modèle et son adaptation aux besoins d'analyse.

Comparaison des modèles relationnel et multidimensionnel

Critère	Modèle relationnel	Modèle multidimensionnel
Objectif	Stocker et organiser les données de manière structurée	Faciliter l'analyse et la prise de décision
Structure	Tables reliées entre elles par des clés étrangères	Tables de faits reliées à des dimensions
Type d'utilisation	Applications transactionnelles (OLTP)	Analyse décisionnelle (OLAP)
Complexité des requêtes	Requêtes souvent complexes avec plusieurs jointures	Requêtes simples et rapides
Organisation des données	Modèle normalisé pour éviter les redondances	Modèle dénormalisé pour améliorer les performances
Exemple dans ce projet	PAYS, VILLE, STATION, CAPTEUR, POLLUANT, INDICATEUR, VALEUR_INDICATEUR	FAIT_MESURE, DIM_TEMPS, DIM_LOCALISATION, DIM_POLLUANT, DIM_PAYS_ECONOMIE, DIM_INDICATEUR, FAIT_INDICATEUR

Conclusion

Le modèle multidimensionnel de type constellation permet d'adapter la structure des données aux besoins d'analyse. En simplifiant les relations et en réduisant le nombre de jointures, il rend les requêtes plus lisibles et plus performantes.

Ce modèle est donc mieux adapté que le modèle relationnel pour l'analyse décisionnelle, notamment pour étudier les liens entre pollution, localisation et indicateurs économiques.

5. Choix stratégique des requêtes

Afin d'évaluer les performances et les capacités d'analyse du modèle multidimensionnel, plusieurs requêtes ont été réalisées selon différents axes.

Certaines requêtes exploitent des opérateurs OLAP tels que ROLLUP, CUBE et GROUPING SETS afin de générer des agrégations avancées. Par exemple, l'analyse de la pollution par pays et par année permet d'obtenir des sous-totaux hiérarchiques, tandis que l'analyse par continent et polluant permet de comparer les niveaux de pollution selon différentes combinaisons.

D'autres requêtes permettent une analyse plus ciblée, notamment par ville, saison ou type de polluant, afin d'identifier des tendances spécifiques et des variations locales.

Enfin, des requêtes plus simples ont été réalisées, comme le calcul de moyennes (par pays, année ou polluant), le comptage du nombre de mesures (par station ou polluant), ainsi que la recherche des valeurs extrêmes (maximum et minimum). Ces requêtes permettent d'obtenir une vision globale des données et d'identifier rapidement les éléments les plus significatifs.

L'ensemble de ces requêtes permet ainsi d'exploiter pleinement les données en combinant des analyses globales, hiérarchiques et ciblées.

Tableau Relationnel vs Multidimensionnel

Requête	Relationnel	Multidimensionnel
Q1	0.183ms	0.107ms
Q2	0.073ms	0.112ms
Q19	0.066ms	0.070ms
Q17	0.150ms	0.095ms

Conclusion

Les requêtes réalisées permettent d'exploiter efficacement les données selon différents axes d'analyse. L'utilisation d'opérateurs OLAP facilite l'obtention de résultats hiérarchiques et de comparaisons pertinentes.

Les tests de performance montrent que le modèle multidimensionnel est globalement plus adapté aux analyses complexes, notamment grâce à la réduction du nombre de jointures.

6. Choix de la stratégie d'analyse pour la visualisation

Afin de réaliser les visualisations sous Qlik, nous avons fait le choix de nous concentrer sur trois pays représentatifs de différents niveaux de pollution : la Norvège (faiblement polluée), l'Allemagne (moyennement polluée) et la Chine (fortement polluée).

Ce choix n'est pas aléatoire. L'objectif est de comparer des situations contrastées afin de mieux mettre en évidence les différences de comportement des données. En sélectionnant des pays avec des niveaux de pollution très différents, il devient plus facile d'identifier des tendances, des écarts significatifs et des anomalies éventuelles dans les données.

La Norvège a été choisie comme exemple de pays peu pollué, en raison de sa politique environnementale stricte et de sa faible densité industrielle. À l'inverse, la Chine représente un cas de forte pollution, liée à une industrialisation importante et à une forte densité de population. L'Allemagne constitue un cas intermédiaire, permettant d'observer une situation plus équilibrée entre développement économique et régulation environnementale.

Cette approche comparative permet ainsi de valider la cohérence des données issues des datasets. En effet, si les visualisations montrent des différences logiques entre ces trois pays, cela confirme la fiabilité du modèle et des données utilisées.

De plus, cette stratégie permet d'éviter une analyse trop globale qui pourrait masquer certaines spécificités locales. En se concentrant sur des cas précis, les graphiques deviennent plus lisibles, plus pertinents et plus faciles à interpréter.

Enfin, cette sélection permet d'exploiter pleinement les capacités de Qlik, en mettant en évidence des variations significatives entre les pays, que ce soit au niveau des polluants, du temps et des indicateurs économiques ou bien démographiques.

6.1 Analyse d'un sous-ensemble critique (détection d'anomalies)

L'analyse des données a permis d'identifier une anomalie significative concernant l'évolution de la pollution en Chine.

En effet, la pollution moyenne passe de 66.84 $\mu\text{g}/\text{m}^3$ en 2021 à 27.23 $\mu\text{g}/\text{m}^3$ en 2022, soit une diminution de plus de 50 % en une seule année. Cette baisse est particulièrement brutale comparée aux années précédentes, où la diminution était progressive.

À titre de comparaison, l'Allemagne et la Norvège présentent des évolutions beaucoup plus stables sur la même période, avec des variations faibles et cohérentes. Cette différence de comportement met en évidence une incohérence potentielle dans les données chinoises.

Plusieurs hypothèses peuvent expliquer cette anomalie :

- la présence de données manquantes ou incomplètes pour l'année 2022
- une modification des méthodes de mesure ou de collecte des données
- ou encore un événement ponctuel ayant temporairement réduit les niveaux de pollution

Cette analyse montre l'importance de ne pas interpréter les données de manière brute, mais de les confronter à leur cohérence globale.

Ainsi, l'étude de ce sous-ensemble critique permet de valider la fiabilité générale du modèle tout en identifiant ses limites potentielles.

Cette baisse peut également être liée à des événements réels, comme les confinements liés à la pandémie de COVID-19, qui ont entraîné une diminution temporaire de l'activité industrielle et donc des émissions de pollution dans certains pays.

Conclusion générale

Ce projet nous a permis de mettre en œuvre l'ensemble des étapes d'un processus d'analyse de données, depuis l'intégration et le nettoyage des datasets jusqu'à leur exploitation à l'aide de modèles relationnels et multidimensionnels.

Il met en évidence l'intérêt du modèle multidimensionnel pour l'analyse décisionnelle, ainsi que l'importance de la qualité des données dans la fiabilité des résultats. Enfin, l'utilisation de Qlik a permis de visualiser les données de manière claire et de confirmer la cohérence des analyses réalisées.